

SAR-EO 영상 융합을 활용한 트리 기반 모델의 토지 피복 분류

SAR and Optical Data Fusion for Land Classification using Tree-based Methods

유호영¹ · 이가람² · 전원준³ · 방지용⁴

You, Ho Yeong · Lee, Ga Ram · Jeon, Won Jun · Bang, Ji Yong

Abstract

Optical satellite images or aerial ortho-images are commonly used in the creation of land cover maps. Optical satellite images allow for the capture of various spectral characteristics using short wavelengths, but they are influenced by weather conditions. In contrast, Synthetic Aperture Radar (SAR) images utilize longer wavelengths and can observe less sensitively to time and weather. Therefore, the fusion of these images can improve the accuracy and completeness of land cover information. In this study, we used multi-sensor fusion technology to combine the information obtained from the bands of optical and SAR images to generate new information, and we proposed the use of tree-based models for land cover classification. We trained a model (Random Forest) on the images from each sensor and applied the model to the fusion images to compare accuracy. In addition, two models (XGBoost, LightGBM) were applied to the fusion images. The process also included extracting optimal parameters through hyperparameter tuning such as random search.

초 록

토지 피복지도를 제작함에 있어 사용하는 영상은 주로 광학 위성 영상 혹은 항공 정사영상이다. 위성 광학 영상은 짧은 파장으로 다양한 분광 특성을 파악할 수 있지만 날씨에 영향을 받는다. 반면, SAR(Synthetic Aperture Radar) 영상은 긴 파장으로 이용하여 시간과 날씨에 덜 민감하게 관측할 수 있다. 따라서 이러한 영상들을 융합하여 토지 피복 정보의 정확성과 완전성을 향상시킬 수 있다. 본 연구에서는 광학 영상과 SAR 영상의 밴드로부터 얻은 정보를 결합하여 새로운 정보를 생성하는 다중 센서 fusion 기술을 사용하였고, 토지 피복 분류에 수행하기 위해 트리 기반 모델 활용을 제안한다. 센서 별 영상에 대해 모델(Random forest) 학습을 진행하였고 fusion 영상에도 모델을 적용해 정확도를 비교하는 과정으로 구성했다. 또한 fusion 영상에 추가로 2 가지 모델(XGBoost, LightGBM)을 적용하였다. 랜덤 서치 등의 하이퍼 파라미터 튜닝을 통해 최적의 파라미터를 추출하는 과정도 포함시켰다.

¹ 에너지자원공학과 4 학년

² 지구자원시스템공학과 3 학년

³ 지구자원시스템공학과 3 학년

⁴ 지구자원시스템공학과 3 학년

1. 서론

토지 피복지도는 토지의 특성과 토지 피복 상태를 시각적으로 표현한 지도로서, 토지 관리 및 자원 보호에 매우 중요한 역할을 수행한다. 이를 통해 토지의 품질, 토양 침식, 수분 보유력, 재배 가능성 등을 파악하여 토지 사용 계획과 자원 관리를 위한 결정을 내리는 데 도움을 준다. 또한, 토지 피복지도는 자원 보호와 환경 관리에 관련된 정보를 제공하며, 토지 이용의 최적화와 토지 관련 의사 결정에 필수적인 자료로 활용될 수 있다. 토지 분류는 현장조사, 항공 영상과 위성 영상의 광학 영상과 SAR(Synthetic Aperture Radar) 영상 등 다양한 데이터 소스에서 획득될 수 있다. 최근 수많은 인공위성이 지구 궤도로 발사되어 광학 영상과 SAR 영상에 대한 자료 접근이 쉬워졌다. 이에 따라 위성 영상들을 빅데이터로 활용하여 지구의 재난 재해, 안보, 환경 등의 분야에 대한 실시간 모니터링이 가능하다.

광학 영상은 전자기파의 파장 중 가시광선, 적외선 대역을 안테나로부터 송수신하여 생성되는 영상이다. 파장이 비교적 짧아 물체의 분광 정보와 같은 화학적인 특성을 알 수 있다. 하지만, 대기의 구름을 투과하지 못해 날씨의 영향을 많이 받는다. SAR 영상은 안테나로부터 마이크로파 대역을 송수신하여 생성되는 영상이다. 밴드의 파장이 광학 영상보다 길어 시간과 날씨에 상관없이 전천후 관측이 가능하다. 따라서, 지표의 물리적인 특성을 잘 파악할 수 있다. 예를 들어, 다중 편파 정보를 활용하여 토지의 속성을 알 수 있다. 하지만 SAR 영상은 위상 정보의 상호 간섭으로 인한 speckle 현상이 나타난다. Speckle은 영상에서 산란 값들의 곱셈 형식으로 나타나 있어 잡음처럼 인식되어 영상 분석에 많은 어려움을 준다. 이처럼 각 영상은 고유한 장점과 한계를 가지고 있으며, 이러한 단일 센서의 한계로 인해 토지 피복 정보의 정확성과 완전성에 제한이 생긴다.

최근 SAR 영상과 광학 영상을 fusion 하여 다양한 분야에 활용되는 연구가 많이 이루어지고 있다. 다중 센서 fusion은 다양한 센서로부터 얻은 정보를 결합하여 새로운 정보를 생성하는 과정을 의미한다. 즉, SAR 영상과 광학 영상을 융합함으로써 두 영상의 장점들은 살리되, 한계를 보완하여 토지 피복 정보의 정확성과 완전성을 향상시킬 수 있다.

대량의 위성 영상들을 처리하기 위해 트리 기반 모델(Random Forest, XGBoost, LightGBM)들을 활용하여 토지 피복 분류에 활용하였다. 우선, 트리 기반 모델들은 하나의 트리만이 아닌 여러 가지의 트리의 특징을 고려하여 기준을 생성하고 예측을 수행할 수 있다. 그리고 각 feature 특징의 중요도를 추정할 수 있어 어떤 특징이 토지 피복

분류에 가장 유용한지를 알려줄 수 있어 트리 모델들을 활용하게 되었다.

2. 트리 기반 모델

2.1 Random Forest

Random forest는 앙상블 학습 알고리즘으로, 여러 개의 결정 트리를 기반으로 분류 및 회귀 문제를 해결하는 방법이다 (Lakshminarayanan et al., 2014). 이때, 무작위한 여러 개의 결정 트리의 예측 결과를 결합하여 더 강력하고 안정적인 예측을 수행한다 (Scornet et al., 2015). 각 결정 트리에 대해 독립적으로 학습하고 그들의 예측 결과를 투표 혹은 평균화하여 최종 예측을 수행한다. 학습 데이터의 부분 집합을 무작위한 추출하여 학습하기 때문에 기존 결정 트리의 overfitting 문제를 완화할 수 있다. 따라서, Random forest 모델을 다음과 같이 정리할 수 있다.

- (1) Bootstrap sampling: 학습 데이터에서 중복을 허용하여 랜덤하게 샘플을 선택함으로써 여러 개의 bootstrap 샘플을 생성한다. 이는 각 결정 트리에 다양한 학습 데이터를 제공하여 다양성을 증가시키는 데 도움을 준다.
- (2) Random feature selection: 각 결정 트리의 split을 수행할 때, 랜덤하게 특성을 선택하여 그 중에서 최적의 split을 찾는다. 이는 트리 간의 상관 관계를 줄이고 다양한 특성의 중요도를 평가하는 데 도움을 준다.
- (3) 투표(또는 평균화): 각 결정 트리의 예측 결과를 종합하여 최종 예측을 수행한다. 보편적으로, 분류 문제의 경우는 다수결 투표를 사용하고, 회귀 문제의 경우는 평균을 계산한다.




Fig 1. Random forest architecture

2.2 XGBoost

XGBoost(Extreme Gradient Boosting)는 Random forest에 비해 조금 더 진보된 알고리즘으로 gradient boosting 방법을 사용한다. Gradient boosting은 여러 개의 결정 트리를 조합해서 더 강력한 예측 모델을 생성해내는 앙상블 기법이다.

즉, 예측이 잘 수행되지 못한 값들에 가중치를 두어 다음 모델에 부여하는 방식이다. 이러한 과정을 순차적으로 반복해서 더 강한 예측 모델을 만드는 것이 이 기법의 원리이다.

구체적인 수행 순서는 다음과 같다. 우선 초기 모델로 초기 예측값을 생성한다. 이때, 제대로 예측할 확률을 y 라 하면, y 에는 오차에 대한 확률도 존재하게 된다. 이 오차를 최소화하기 위해 gradient(기울기)를 계산한다. Gradient 는 손실 함수의 미분 값으로, 오차를 줄이는 방향을 제시한다. 만약, 결측값이 있는 경우에는 이를 대체할 값을 추정하지만 일반적으로는 트리 분할 기준에 의해 결정된다. 이후 새로운 트리의 오차를 줄이기 위해 gradient 를 이용해 최소 오차를 구한다. 새로운 트리는 오차를 보완하는 데 집중하여 잔차를 예측해 모델을 업데이트한다. 이때 모델의 복잡도를 제어하기 위해 정규화 및 제약 조건을 사용하고, 파라미터를 조정하여 과적합을 방지한다. 새로운 트리를 계속 추가할수록 예측값이 점차 업데이트된다. 최종적으로, 모든 트리의 예측값을 합하여 최종 예측 모델을 만들 수 있다.




Fig 2. XGBoost architecture

$$F_m(X) = F_{m-1}(X) + \alpha_m h_m(X, r_m) \quad (1)$$

식 1 에서 α_i, r_i 는 정규화 파라미터이며, h_i 는 잔차를 예측하기 위해 학습된 함수이다. F_m 는 예측 모델을 의미하며, 이는 추가된 트리의 예측값이 합산된 값이다. 이처럼, 정규화 기법이 사용된 XGBoost 는 복잡한 모델에 대해 페널티를 적용하여 overfitting 을 억제한다.

2.3 LightGBM

LightGBM(Light Gradient Boosting Machine, LGBM)은 마찬가지로 트리 기반의 학습 알고리즘인 gradient boosting 방식의 모델이다. 하지만, XGBoost 와는 다른 방식의 분할 방법을 사용한다. 기존 알고리즘의 경우 트리를 순차적으로 분할하여, 한 레벨의 노드가 분할되면 다음 레벨로 진행되는 방식이다(Level-wise tree growth). 하지만 LGBM 의 경우

노드를 분할할 때, 최대 손실 값을 갖는 leaf 노드를 지속적으로 분할한다(Leaf-wise tree growth). 그렇기에 leaf-wise 알고리즘은 다른 level-wise 알고리즘보다 낮은 loss 를 달성하는 경향이 있다. 데이터의 크기가 작은 경우, leaf-wise 는 overfitting 이 되기 쉬우므로 'max_depth' 파라미터를 줄여줘야 한다. LGBM 은 대용량 데이터셋 및 차원이 높은 데이터셋에서 탁월한 성능을 발휘한다. 또한 LGBM 은 파라미터 튜닝과 조정이 상대적으로 쉽고, 학습 데이터에 대한 encoding 을 자동으로 수행하여 속도가 빠르다.

3. 실험 방법

3.1 실험 데이터 생성

본 연구에서 토지 피복을 수행할 지역은 세종시이다. 세종시는 대한민국의 특별자치시의 하나로 정부 기관들이 들어서 있는 도시이다. 북서부(전의군 지역)는 산악 지형이며, 남동부는 평지로 이루어진 지형 구조를 갖고 있다. 인구의 대다수는 강 주변의 평지에 위치한 행정중심복합도시에서 거주하고 있다. 이처럼 주변에 다양한 지형지물을 띠고 있어 토지 피복을 수행하기에 있어서 적합하다는 판단이 들어 연구지역으로 선정하게 되었다.

토지 피복 분류를 위한 영상들은 ESA(European Space Agency)에서 구축한 'Copernicus' 프로그램의 Sentinel-1(1A, 1B), Sentinel-2(2A, 2B) 위성을 통해 획득하였다. 'Copernicus' 프로그램은 다양한 센서를 탑재한 위성들을 운용 중에 있으며, 그 중에서도 Sentinel-1 은 SAR 을, Sentinel-2 는 EO 센서를 탑재하고 있다. 사용한 위성 자료들은 모두 SNAP(Sentinel Application Platform) 소프트웨어의 graph builder tool 을 활용하여 처리하였다. SAR-EO 영상 처리 시간의 효율을 위해 subset((127.2305, 35.5044), (127.2992, 36.4690))를 진행한 후 각 영상들의 전처리 과정을 수행하였다.

3.1.1 Sentinel-1 영상 전처리

사용한 7장의 자료들은 모두 GRD(Ground Range Detected) 영상으로, 위상 성분은 제외한 진폭값만을 활용하였다. 또한, 이중 편파(VV+VH) 정보를 머신러닝 분석에 활용하였다. 일반적으로 VV 편파는 표면의 거친 정도와 관련이 있으며, VH 편파는 표면의 굴곡과 관련이 되어 있다. 이러한 다양한 편파 정보를 활용하여 지표면의 물리적인 특성에 대해 알 수 있었다. 더불어, speckle 에 의한 잡음 효과를 조금 상쇄시키고 또 다른 물체 특성에 대한 정보를 VV 편파와 VH 편파의 비율 정보를 활용하였다. SAR 영상의 전처리 과정은 Fig 3 과 같다.




Fig3. SAR preprocessing graph builder

우선, 정밀 궤도 정보를 적용한다. 이는 촬영한 시점에서의 위성의 위치와 방향에 대한 정보를 제공한다. Thermal noise removal 과정은 전자 기기에서 발생하는 무작위 열 잡음을 제거하는 과정이다. 실제 지표 반사율에 대한 분석을 수행하기 위해 σ^0 값으로 변환하였다. 이후, SAR 영상 분류를 원활히 수행하기 위해 speckle 잡음을 공간 필터링 기법인 refined lee 필터를 활용하여 줄여주었다. SAR 영상 픽셀들은 밝기 차이가 크고 다양한 산란 강도를 보여 dB 로 변환한 뒤 사용하였다. 마지막으로, orthorectification 과정을 진행했다. SAR 영상은 side looking 하는 특징이 있어 실제 지형에 맞게 조정하기 위해 이 과정을 수행했다. 사용된 DEM(Digital Elevation Model)은 30m 해상도를 갖는 'Copernicus DEM GLO-30'이다.

3.1.2 Sentinel-2 영상 전처리

다중 스펙트럼 정보를 사용하기 위해 Sentinel-2 의 'B1'(433nm)부터 'B12'(2190nm) 총 11 개의 밴드를 활용하였다. 또한, feature engineering 단계에서 유용한

정보로 사용될 수 있는 vegetation index 를 구하기 위해 SNAP 소프트웨어의 bandmath 기능을 활용하였다. NDVI는 식물의 생장 상태와 식생량을 추정하기 위해 사용되는 지표이며, NDWI 는 수계를 추정하기 위해 사용된다. 두 개의 밴드 모두 근적외선(NIR) 영역을 사용한다는 공통점이 있다. 이외에도 REI(Red Edge Index)와 EVI2(Enhanced Vegetation Index) 값을 활용했다. EVI2는 NDVI에서 조금 더 진보된 vegetation index 이다.

Table 1 에서 밴드마다 공간 해상도가 다른 것을 볼 수 있다. 해상도를 통일하기 위해 Sentinel-1 의 10m 해상도에 맞춰 Sentinel-2 모든 밴드에 대해 resampling 과정을 진행했다.

Table 1. Sentinel-2 specifications

Band ID	Resolution(m)	Wavelength
B01	60	443
B02	10	490
B03	10	560
B04	10	665
B05	20	705
B06	20	740
B07	20	783
B08	10	842
B09	60	945
B11	20	1610
B12	20	2190

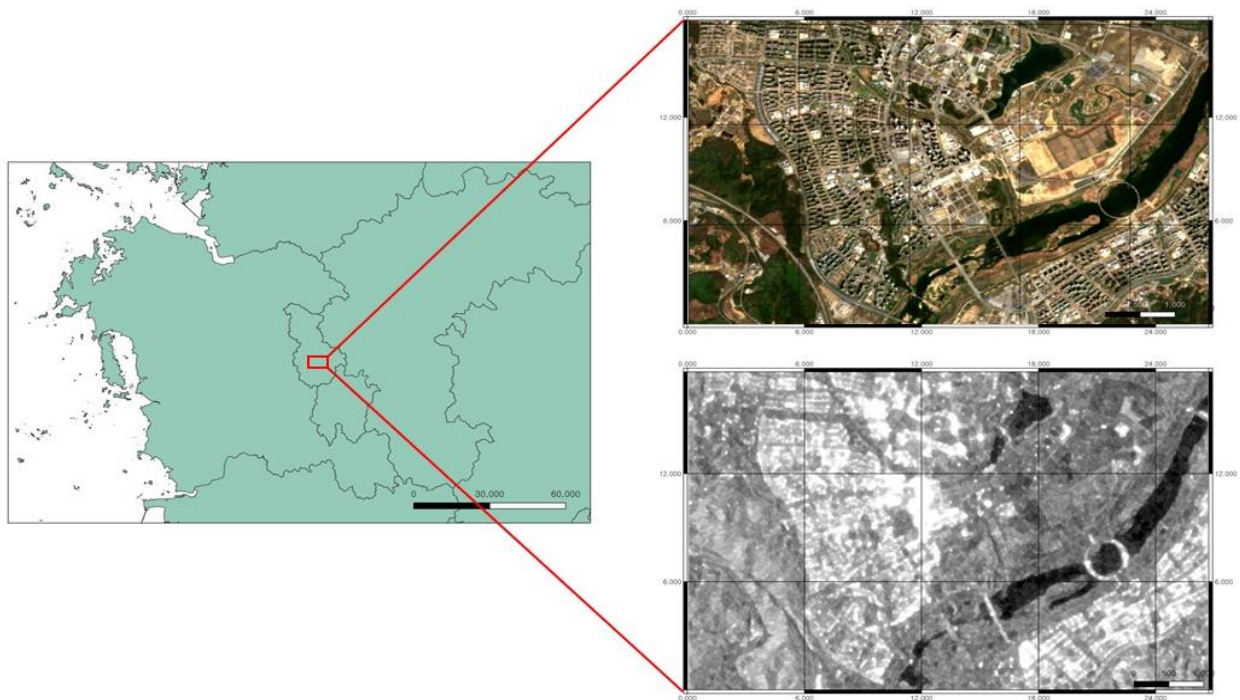


Fig 4. SAR and optical image of study area, Sejong si, South Korea

3.1.3 SAR-EO Fusion

완벽히 동일한 시점에 대해 Sentinel-1 과 Sentinel-2 영상을 획득하는 것은 어렵기 때문에, 각 fusion 영상에 대해 ± 7 일 이내가 되도록 영상을 다운로드 하였다(Table 2). 따라서 총 7장의 fusion 영상을 획득할 수 있었다.

Table 2. Sentinel image acquisition dates

Sentinel-1 Date	Sentinel-2 Date	Δ Days
2022-04-11	2022-04-17	6
2022-04-23	2022-04-27	4
2022-05-17	2022-05-17	0
2022-05-29	2022-06-01	2
2022-06-10	2022-06-11	1
2022-09-14	2022-09-09	-5
2022-09-26	2022-09-24	-2

서로 다른 센서의 영상을 융합하기 위해 SNAP 의 ‘Collocation tool’을 사용했다. 영상들을 일치시킬 때, secondary(EO) 영상을 reference(SAR) 영상 래스터에 맞게 픽셀들이 resampling 된다. SAR, EO 영상이 각각 갖고 있던 밴드들이 하나의 파일 안에 합쳐지게 된다. Resampling 될 때는 다음 기법 중 하나가 사용된다: Nearest neighbour, bilinear interpolation, cubic convolution.

3.2 학습 데이터 생성

학습 데이터 label 생성을 위해 토지 피복 분류체계를 참고하여 활용하였다. 환경공간정보서비스에서 제공하는 토지 피복의 분류체계는 대분류, 중분류, 세분류로 총 3 가지이다. 대분류는 해상도 30m 급, 중분류는 해상도 5m 급, 세분류는 해상도 1m 급이다. 하지만 Sentinel-1 과 Sentinel-2 위성은 10m 의 공간 해상도로 resampling 하였다. 10m 의 공간 해상도란 두 물체를 구분하기 위해서는 최소 거리가 10m 이어야 한다는 것을 뜻한다. 따라서 5m 의 중분류 label 을 택하면 과적합이 발생할 수 있다. 즉, 10m 의 공간 해상도로 인해 두 물체를 정확하게 구분하기 어려울 수 있다. 이에 따라 대분류에서 구분해 놓은 label로 학습 데이터를 생성하였다.

기존의 중분류의 경우 총 label 개수가 20 개였다. 하지만 10m 해상도 급에서 이를 모두 분류하는 것은 어렵기 때문에 대분류 label 을 활용하였다. 대분류는 Used area (시가지 및 건조지역), Agricultural land (농업지역), Forest (산림지역), Grass (초지), Wet land (습지), Barren (나지), Water (수역) 등 7 가지의 항목으로 구분할 수 있다. 환경공간정보서비스에서 제공하는 shp 파일을 다운받아 QGIS 를 통해 label 을 생성하였다. QGIS 에서는 표현식을 통해 새로운 ‘L1_CODE’

레이블을 재생성하였다. 재생성 과정은 Table 3을 통해 확인할 수 있다.

Table 3. Psuedo code for label

Algorithm 1: Generating label data in QGIS

Input: label .shp
Output: new label .shp
1. case 1: ‘L2_CODE’ GT 100 and LT 200, then 100
2. case 2: ‘L2_CODE’ GT 200 and LT 300, then 200
3. case 3: ‘L2_CODE’ GT 300 and LT 400, then 300
4. case 4: ‘L2_CODE’ GT 400 and LT 500, then 400
5. case 5: ‘L2_CODE’ GT 500 and LT 600, then 500
6. case 6: ‘L2_CODE’ GT 600 and LT 700, then 600
7. case 7: ‘L2_CODE’ GT 700 and LT 800, then 700

3.3 모델 학습

3 가지 분야로 구분하여 Random forest 모델로 학습시켰다. 우선 SAR 영상에 대해 단일, 평균, 시계열 영상에 대해 학습을 진행했다. 이후, EO, fusion 영상에 대해서는 단일, 시계열 영상에 대해 학습을 진행했다. 마지막으로, fusion 영상에 추가로 XGBoost, LGBM 기법을 활용하여 트리 모델 간 비교를 진행하였다.

3.3.1 SAR

SAR 영상의 Pixel 기반 머신러닝을 수행하였다. 우선 단일 영상(2022-04-11 영상) 으로는 feature을 ‘VV’, ‘VH’, ‘VV/VH’, 총 3 가지를 놓고 label 데이터를 학습시켰다. 단일 영상의 경우 refined lee 필터가 적용되어 있다. 만약 공간 특성 정보를 조금 더 향상시키고자 한다면 시계열 평균 영상을 활용할 수 있다. 공간 필터링의 경우 커널을 사용하여 smoothing 효과가 나타나 경계 부분에 대한 해상도가 떨어지는 반면 시계열 필터링의 경우 해상도는 유지되면서 speckle을 줄여줄 수 있어 경계 부분에 대한 특징 보존이 가능해지는 장점이 있다. 두 기법에 대한 비교 이후, 시계열 자료를 수평적으로 쌓아 학습을 진행하였다.

3.3.2. EO

EO 영상에는 ‘B1’ 부터 ‘B12’와 더불어 vegetation index 까지 총 15 개의 밴드가 존재한다. 이를 단일 영상에 대해 label 데이터를 학습시켰다. 이후, 시계열 자료를 모두 수평적으로 포함시켜 총 105 개의 밴드를 학습시켰다. 모델의 feature 수가 늘어남에 따라 복잡도가 올라가 overfitting 의 위험이 있는 것을 확인할 수 있었다. 따라서, 하이퍼 파라미터 조정을 통해 적절한 파라미터를 추출하여 적용해주었다.

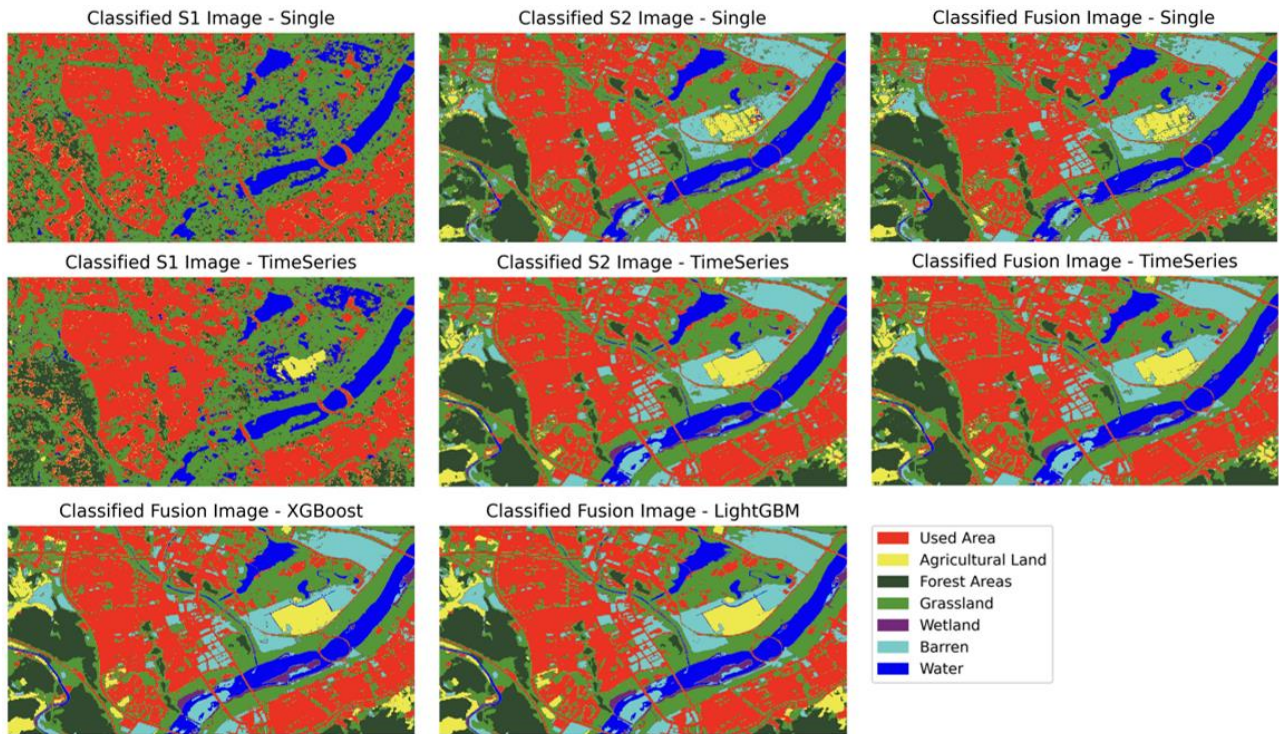


Fig5. Classification result of SAR, optical and fusion image

3.3.3. Fusion

기존 SAR과 EO의 feature들을 융합하여 총 18개의 밴드를 단일 영상에 대해 학습을 시켰다. 마찬가지로, 7장의 시계열 자료에 대해 126가지(18x7)의 밴드를 통해 학습을 시켰다. Random forest 모델의 경우 overfitting이 나타나는 것을 파악했다. 하이퍼 파라미터 튜닝을 위한 시간 소요가 컸다. 이에 따라, gradient boosting 기법을 사용하는 XGBoost와 LightGBM 모델을 적용하여 overfitting을 완화하는 동시에 예측력을 향상시켰다. 병렬적인 처리가 가능해져 시간 소요가 많이 줄은 것을 확인할 수 있었다.

4. 결과 및 분석

4.1 평가

4.1.1 정확도 평가

Fig 4에서는 SAR, EO, Fusion 영상들에 대해 시각적인 비교를 통해 결과를 분석하였다면, 이번에는 수치적으로 어떠한 차이가 나며, 의미를 가지는지에 대해 확인해 볼 예정이다. 정확도 평가에 accuracy score, confusion matrix, classification report를 사용했다. 첫번째로 SAR, EO, fusion 영상들의 단일 영상, 시계열 영상에 대한 분석을 진행하고, 두번째로 앞선 결과에서 가장 좋은 데이터셋을 선택해 트리 기반 알고리즘에 대한 모델 정확도 분석을 해보려 한다.

classification report는 최종적으로 가장 정확도가 높게 보이는 모델에서만 볼 것이다.

(1) Accuracy score

정확도 점수는 분류 모델의 성능을 나타내는 지표 중 하나로, 모델이 입력 데이터를 올바르게 분류한 비율을 나타낸다. 보통 0과 1 사이의 값을 가지며, 1에 가까울수록 모델이 더 정확하게 예측한다는 것을 의미한다. 모델의 전체적인 성능을 평가하는 데 사용되며, 모든 클래스에 대한 분류 결과를 종합적으로 고려한다. 따라서, 모델의 예측 성능을 평가하고 비교하는 데 유용한 지표이다.

(2) Confusion matrix

Confusion matrix(혼동 행렬)는 분류 모델의 성능을 평가하기 위해 사용되는 표이다. 이 표는 모델의 예측 결과와 실제 클래스 간의 관계를 나타내며, 모델이 각 클래스를 얼마나 정확하게 예측했는지를 보여준다. 이진 분류(Binary Classification) 뿐만 아니라 다중 클래스 분류(Multi-Class Classification)에서도 사용된다. TP(True Positive)는 실제로 Positive인 샘플을 모델이 정확하게 Positive로 예측한 경우를 나타낸다. FN(False Negative)은 실제로 Positive인 샘플을 모델이 Negative로 잘못 예측한 경우이다. FP(False Positive)는 실제로 Negative인 샘플을 모델이 Positive로 잘못 예측한 경우이며, TN(True Negative)은 실제로 Negative인 샘플을 모델이 정확하게 Negative로 예측한 경우이다.

(3) Classification report

Classification report(분류 보고서)는 분류 모델의 성능을 상세히 설명하는 보고서 형식의 표이다. 일반적으로 다중 클래스 분류(Multi-Class Classification)에서 사용되며, 각 클래스에 대한 주요 평가 지표를 포함한다. 주요 지표로는 정밀도(Precision), 재현율(Recall), F1-score, 그리고 지원 샘플 수(Support) 등이 있다.

Precision 은 해당 클래스로 예측한 데이터 중 실제로 해당 클래스인 데이터의 비율을 나타낸다. Recall 은 실제로 해당 클래스인 데이터 중 해당 클래스로 예측한 데이터의 비율을 나타낸다. f1-score 는 precision 과 recall 의 조화 평균으로 계산되며, 클래스의 예측 성능을 종합적으로 평가하는 지표이다. Support는 각 클래스에 속하는 실제 샘플의 개수를 나타낸다.

또한, micro avg 는 전체 클래스에 대한 평균을 계산한 지표이다. macro avg 는 각 클래스에 대한 평균의 평균을 계산한 지표이다. weighted avg 는 클래스에 대한 샘플 수로 가중 평균을 계산한 지표이다.

4.1.1.1 S1 vs S2 vs Fusion

Table 4. Single image accuracy score

Data	정확도 점수
S1 Only	X_test, y_test
	0.5024
S2 Only	X,y
	0.5104
Fusion	X_test, y_test
	0.7780
Fusion	X,y
	0.8293
Fusion	X_test, y_test
	0.7926
Fusion	X,y
	0.8455

Table 5. Timeseries images accuracy score

Data	정확도 점수
S1 Only	X_test, y_test
	0.5983
S2 Only	X,y
	0.6554
S2 Only	X_test, y_test
	0.8356
Fusion	X,y
	0.8888
Fusion	X_test, y_test
	0.8460
Fusion	X,y
	0.9076

전체적인 정확도 점수를 보면 단일 영상을 데이터로 설정해 분류를 하는 것보다, 시계열 영상을 이용해 분류하는 것이 더 좋게 나왔다. 또한, 두 데이터셋 모두 Sentinel-1 을 단독으로 사용할 때 점수가 가장 낮게 나왔고 그 다음으로는 Sentinel-2 만 단독으로 사용했을 때, 마지막으로 fusion 영상이 가장

정확도 값이 높게 나왔다. Confusion matrix 를 봐도 더 TP의 비율이 높음을 확인할 수 있었다. 이와 같은 결과가 나온 이유는 Sentinel-1 영상에는 잡음과 같은 지표 정보를 방해하는 요소가 있기 때문이다. Sentinel-2 영상만 사용하는 것과 fusion 영상을 사용한 정확도 점수, Confusion matrix 모두 결과값은 비슷하지만 Fusion 영상이 좀 더 높게 나왔는데, Sentinel-2 에서는 담아내지 못했던 지표 정보를 Sentinel-1 에서 얻을 수 있었음을 볼 수 있었다.




Fig 6. Sentinel-1 Time series confusion matrix

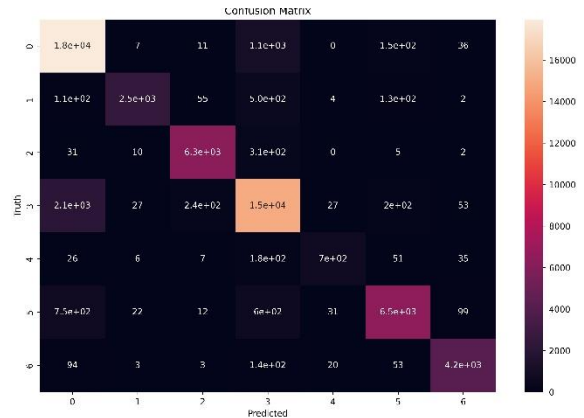


Fig 7. Sentinel-2 Time series confusion matrix




Fig 8. Fusion Time series confusion matrix

단일 영상과 시계열 영상으로 영상 데이터 셋을 나누어서 random forest 분류모델 적용을 해보았는데, 그 이유는 실제로 토지 피복도를 만들 때 1~2 년간의 영상을 종합하여 만들기 때문이다. 그렇기에 시계열 데이터가 좀 더 높은 점수를 가졌고, 토지 피복 지도는 범용적으로 사용되어야 하기 때문에 시계열 영상을 사용해서 일반적인 형태로 만드는 것이 중요하다는 분석을 할 수 있었다.

4.1.1.2 RF vs XGB vs LGBM

Table 6. Fusion image accuracy score

Method		정확도 점수
Random Forest	X_test, y_test	0.8460
	X,y	0.9076
XGBoost	X_test, y_test	0.8785
	X,y	0.9107
LightGBM	X_test, y_test	0.9108
	X,y	0.9517




Fig 9. Random Forest Confusion matrix




Fig 10. XGB Confusion matrix

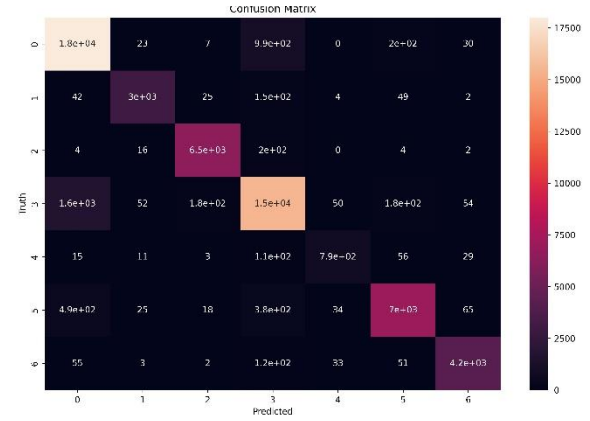


Fig 11. LGBM Confusion matrix

정확도 점수를 보면 Random forest, XGBoost, LightGBM 순으로 좋다. 하지만, Confusion matrix 를 보면 거의 똑같은 결과값이 나온 것처럼 보인다. 그럼에도 불구하고 각각의 값으로 비교해보면 LightGBM 이 좀 더 좋은 결과를 보였을 것이라고 생각된다. Random forest 의 상위 호환 버전이 XGBoost 와 LightGBM 이기 때문에 더 좋게 나왔음을 확인할 수 있었다. 더 나아가 가장 결과값이 좋게 나온 LightGBM 에서의 feature importance 와 classification report 를 살펴보고자 한다.

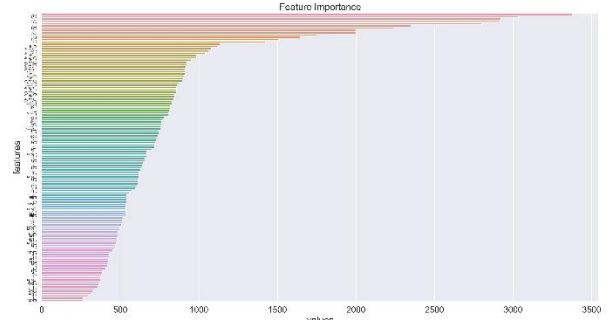


Fig 12. LGBM Feature importance

가장 영향을 크게 준 feature 는 2 번째 영상의 Band 9 이며, 대체적으로 SAR 영상의 편파 정보들도 많은 영향을 주는 것을 확인하였다.

Table 7. Fusion time series LGBM classification report

label	precision	recall	f1-score	support
100	0.89	0.94	0.91	19262
200	0.96	0.92	0.94	3283
300	0.96	0.97	0.97	6696
400	0.89	0.88	0.88	17636
500	0.87	0.78	0.82	1006
600	0.93	0.87	0.9	8001
700	0.96	0.94	0.95	4477

accuracy			0.91	60361
macro avg	0.92	0.9	0.91	60361
weighted avg	0.91	0.91	0.91	60361

4.2 모델 적용

4.2.1. 정확도 평가

학습한 지역 이외의 지역에 대해 예측 과정을 수행해 보았다. 기존 좋은 성능을 보인 LGBM 을 활용하여 새로운 지역을 예측하여 얻은 정확도 점수는 0.6123 으로 성능이 매우 떨어진 것을 알 수 있다. 이는 overfitting 현상이 일어나, 훈련한 지역은 압도적으로 높게 나오고 새로운 데이터에 대해서는 예측 능력이 현저히 떨어지는 것을 말한다.

4.2.2. 시각적 비교

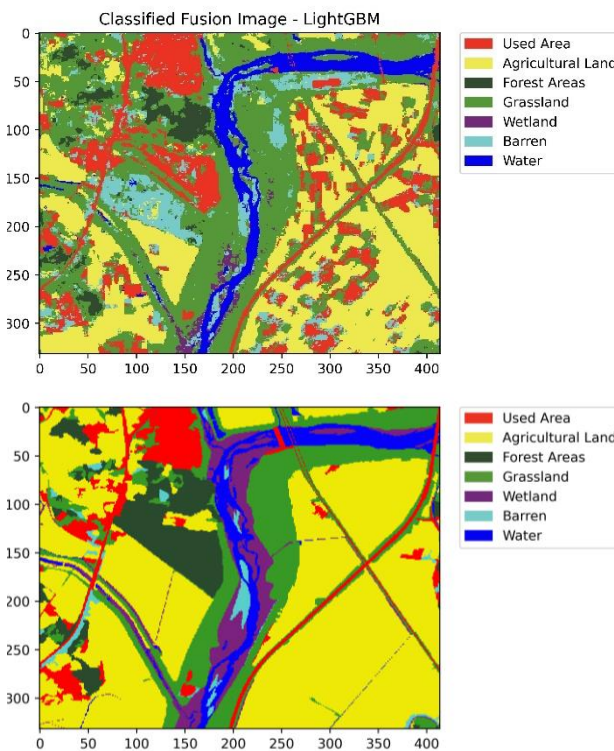


Fig 13. Comparison between prediction and label, Region 2

4.3 딥러닝 모델 분석

4.3.1 MLP

MLP(Multi-layer perceptron) 모델을 이용하여 토지 피복 지도를 예측해 보았다. Input 데이터는 SAR, EO 와 이들을 이용한 fusion 데이터를 이용하였고, 'Min Max Scaler'를 통해 정규화 하여 인공신경망 모델을 학습시켰다.

그리고 정답 레이블은 대분류 7 개로 원핫인코딩(one-hot-encoding) 형식으로 만들었다. 먼저 히든 레이어(18개, 36개,

18 개)인공신경망 모델을 'epochs'=100 으로 고정하고 'learning rate'를 각각 0.01, 0.001, 0.0001 총 3 가지 학습시켰다.

'Learning rate'가 0.001 인 경우가 정확도가 69%로 테스트 정확도가 균일하여 제일 성능이 좋았다. 하지만 만족스러울 정도의 성능이 나오지 않아 중간에 더 큰 사이즈의 레이어를 추가한 히든 레이어 (18,36,72,36,18) 모델과, 레이어의 사이즈는 크지 않지만 더욱더 많은 레이어로 구성된 히든 레이어 (18,18,18,18,18,18,18,18) 모델을 학습시켜 보았다.

히든 레이어 (18, 18, 18, 18, 18, 18, 18, 18) 모델을 'epochs'=100으로 고정하고 'Learning rate'를 각각 0.01, 0.001, 0.0001 총 3 가지 학습시켰다. 'Learning rate'가 0.01 인경우가 성능이 제일 만족스러웠으며 정확도가 72%로 앞선(18,36,18) 모델 보다 성능이 좋아졌음을 알 수 있다.

히든 레이어(18,36,72,36,18) 모델을 'epochs'=100 으로 고정하고 'Learning rate'를 각각 0.01, 0.001, 0.0001 총 3 가지 학습시켰다. 'Learning rate'가 0.001 인경우가 성능이 제일 만족스러웠으며 정확도가 74%로 앞선 인공신경망 모델들 보다 성능이 좋아졌음을 알 수 있다.

따라서 레이어의 개수를 조금 추가하고 레이어의 크기를 더욱 크게 하여 히든 레이어(64,128,256,518) 인공신경망 모델을 'epochs'=30 으로 고정하고 'Learning rate'를 각각 0.01, 0.001, 0.0001 총 3 가지 학습시켰다. 'epochs'를 30으로 고정한 이유는 레이어의 크기가 커 연산이 늘어나 학습시간이 오래 걸리고 'epochs' 30 이상부터 유의미한 모델의 학습보다는 overfitting 을 보였기에 'epochs'는 30 으로 정하였다.

'Learning rate'가 0.001 일때 정확도 93%로 제일 성능이 좋았으나 overfitting 문제가 있어 드롭 아웃 레이어를 추가하여 히든 레이어들 뒤에 'dropout rate' = 0.25 인 값을 추가하였다. 이경우도 같은 모델을 기반으로 해서 'Learning rate'가 0.001 일때 성능이 좋았으나 정확도가 많이 떨어졌다. 그래서 'dropout rate'를 0.1 로 조정하였다. 그 결과 75%의 정확도와 overfitting 도 해결할 수 있었지만 만족스러운 모델을 학습시키지는 못하였다.

그러한 원인으로는 이번 모델들은 사실 MLP(multi-layer perceptron)와 유사하여 1x1 픽셀들을 input 데이터로 가지기 때문에 주변 픽셀과의 관계를 가지고 토지 피복지도를 만든다면 정확도가 올라갈 것이다.

또한 학습지역의 특성상 습지와 농업지역이 부족하였고 농업 지역 또한 비닐하우스에 대한 정보가 없었다. 그렇기에

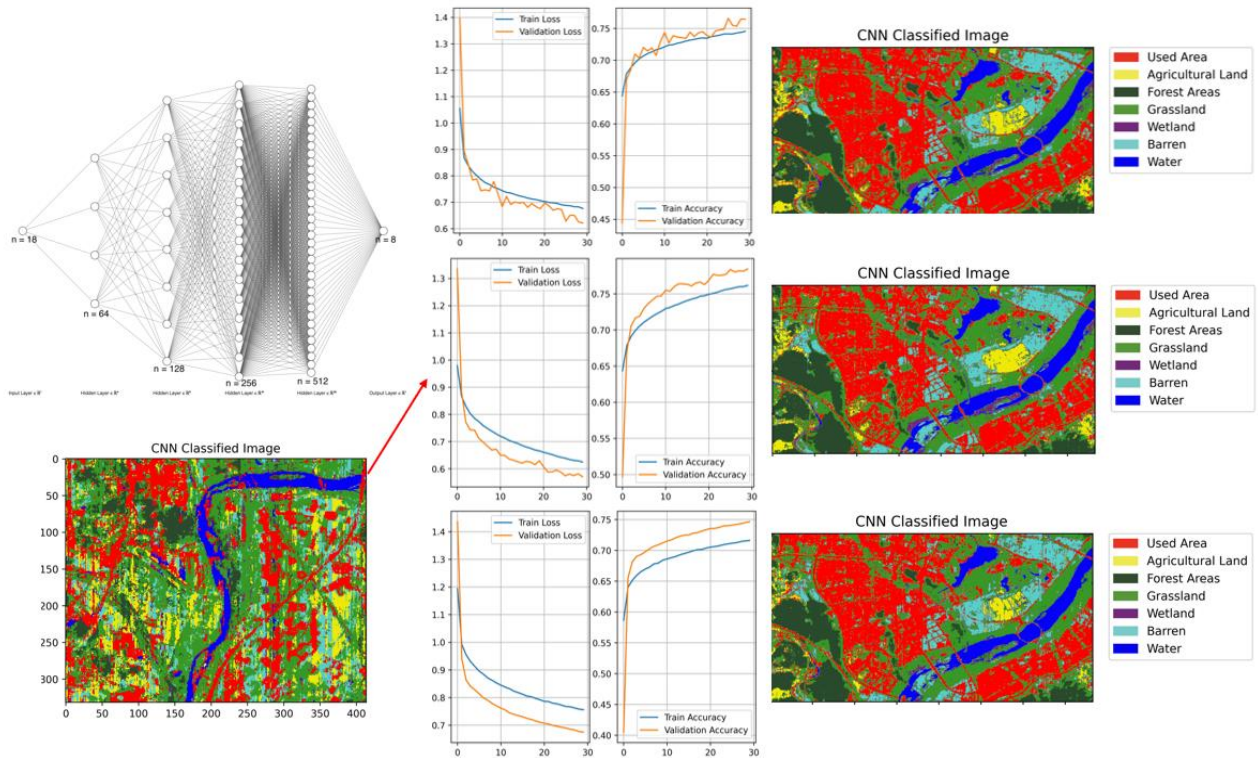


Fig 14. CNN classified image

다른 지역을 분석할 때 비닐하우스를 시가화-건조지역으로 판단을 많이 하였다.

따라서 다양한 항목이 균등하게 분포되어 있는 훈련지역 선정과 방대한 데이터를 nxn 크기의 데이터를 input 으로 받는 CNN 모델을 이용하면 성능이 올라가고 overfitting 또한 완화될 것으로 기대한다.

5. 결론 및 향후 연구

5.1 결론

본 연구에서는 광학 영상과 SAR 영상을 fusion 한 기술을 이용하여 세종 지역의 토지 피복 분류를 시행하고 정밀도를 분석하였다. 선정한 지역에 대해 학습한 모델에 대해 영상 간의 정확도 분석, 모델 간의 정확도 분석을 진행하였다. 추가로 다른 지역에 대한 모델 적용 결과를 분석해보았다.

영상 간의 정확도를 통해 단일 영상과 시계열 영상의 차이를 분석하였다. 단일 영상에서의 최고 정확도는 Fusion 영상에서 0.7926 의 값이다. 또한 시계열 영상에서의 최고 정확도는 Fusion 영상에서 0.8460 의 값이다. 전체적인 정확도는 시계열 영상에서 높았다. 또한 Sentinel-1, Sentinel-2, Fusion 영상 순으로 정확도가 높아진 것을 보아, Sentinel-1 에서 speckle 잡음과 같은 지표 정보를 방해하는 요소가 있다는 것을 알 수 있다. 또한 fusion의 정확도가 Sentinel-2의

정확도보다 높은 것은 Sentinel-1 에서 추가적인 지표 정보가 더해졌기에 나타난 것을 알 수 있다. 따라서 fusion 시계열 영상을 사용하여 토지 피복 지도를 만드는 것이 중요하다고 볼 수 있다.

모델 간의 정확도는 Fusion 시계열 영상에 대해 random forest 와 XGBoost, LightGBM 의 차이를 분석하였다. 세 모델에 대한 정확도는 random forest 에서 0.8460, XGBoost 에서 0.8785, LightGBM 에서 0.9108 으로 도출되었다. 이는 트리 기반 모델에서 random forest 의 상위 호환 버전이 XGBoost 와 LightGBM 이고, 그 중에서도 LightGBM 이 가장 정확도가 좋게 나타났다. 이러한 LightGBM 모델에서의 feature importance 와 classification report 를 살펴본 결과, 가장 큰 영향을 미친 feature 는 두 번째 영상의 Band 9 와 그 다음으로는 SAR 영상들의 편파 정보인 것을 확인할 수 있다.

타 지역에 대해서도 기존에 학습시킨 모델을 적용해본 결과 0.6123 의 결과를 나타낸 것을 확인하였다. 성능이 매우 떨어졌는데, 이는 훈련된 지역에 대한 overfitting 현상이 나타난 것을 알 수 있다. 이러한 결과가 나온 이유는 첫번째, 영상 훈련을 pixel 기반으로 했기 때문에 값이 거의 동일하면 다른 레이블이라고 해도 같은 레이블이라고 판단되기 때문이다. 두번째, 레이블 데이터를 좀 더 해상도에 맞게 세분화를 진행해야 했을 것 같다. 레이블을 중분류를 대분류로

통합시키면서 각 피쳐가 가지고 있던 특성을 무시했다고 볼 수 있다. 그렇기에 논임에도 불구하고 도시지역이라 탐지되는 이유도 그러하다고 생각한다. 마지막으로 훈련시킬 때 다른 지역도 함께 했다면 전체적으로 좋은 점수를 얻었을 수도 있을 것 같다. 본 보고서에서는 한 지역에만 훈련을 진행하였는데, 이로 인해 연구지역에 대한 오버 피팅이 일어났을 것이다. 그렇기에 레이블의 분포가 거의 동일하며, 같은 레이블이더라도 다양한 특성이 포함될 수 있게 데이터 셋을 구축하고 훈련시키야 한다고 분석할 수 있었다.

5.2 향후 연구

따라서, 향후 연구에서는 이러한 현상을 완화하기 위한 추가적인 연구를 진행해보려 한다. 더불어 많은 지역에 대해 모델을 적용할 수 있도록 개선하는 것이 앞으로의 목적이다. 특히, 트리 기반 모델 이외의 인공지능망을 활용하는 CNN (convolutional neural network) 기법을 활용하여 토지 피복 성능을 개선시키고자 한다.

6. 결론

본 연구는 세종대학교 에너지자원공학과 유호영과 지구자원시스템공학과 이가람, 전원준, 방지용에 의해 공동 진행되었다.

7. 참고문헌

[1] Belgiu, Mariana, and Lucian Drăguț. "Random forest in remote sensing: A review of applications and future directions." *ISPRS journal of photogrammetry and remote sensing* 114 (2016): 24-31.

[2] Natekin, Alexey, and Alois Knoll. "Gradient boosting machines, a tutorial." *Frontiers in neurorobotics* 7 (2013): 21.

[3] Gislason, Pall Oskar, Jon Atli Benediktsson, and Johannes R. Sveinsson. "Random forests for land cover classification." *Pattern recognition letters* 27.4 (2006): 294-300.

[4] Rodriguez-Galiano, Victor Francisco, et al. "An assessment of the effectiveness of a random forest classifier for land-cover classification." *ISPRS journal of photogrammetry and remote sensing* 67 (2012): 93-104.

[5] Łoś, H., et al. "Evaluation of XGBoost and LGBM performance in tree species classification with sentinel-2

data." *2021 IEEE International Geoscience and Remote Sensing Symposium IGARSS*. IEEE, 2021.

[6] Ke, Guolin, et al. "Lightgbm: A highly efficient gradient boosting decision tree." *Advances in neural information processing systems* 30 (2017).

[7] Al Daoud, Essam. "Comparison between XGBoost, LightGBM and CatBoost using a home credit dataset." *International Journal of Computer and Information Engineering* 13.1 (2019): 6-10.

[8] Yang, Chun, Franz Rottensteiner, and Christian Heipke. "Classification of land cover and land use based on convolutional neural networks." *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences* 4 (2018), Nr. 3 4.3 (2018): 251-258.